

Studio e Valutazione di Large Language Models per la generazione di Query Ibride SQL-Cypher

Tirocinante: Mattia Rocchi

Tutor didattico: Golfarelli Matteo

Laboratorio: Business Intelligence Lab, Stanza 4136

Periodo di svolgimento: 01/09/2025 – 03/11/2025

1. Introduzione

Il presente tirocinio si è svolto all'interno di un contesto di ricerca, focalizzato sull'uso di modelli di linguaggio avanzati (Large Language Models, o LLM) per facilitare l'interrogazione di database NoSQL complessi.

I database a grafo, in particolare, rappresentano un'architettura dati efficace per modellare relazioni complesse, trovando applicazione in numerosi domini, incluso quello agricolo oggetto di questo studio. Tuttavia, l'accesso a questi dati richiede la conoscenza di linguaggi di query specifici come **Cypher**.

L'obiettivo di questo tirocinio è stato valutare lo "state-of-the-art" dei LLM nel tradurre in modo efficace le richieste da linguaggio naturale in query valide.

La sfida è resa più complessa dal contesto tecnologico, che spesso include non solo database a grafo puri come **Neo4j**, ma anche ambienti ibridi come **PostgreSQL** con l'estensione **AGE** (A Graph Extension) per i grafi e **TimescaleDB** per le serie temporali. Questo richiede la gestione di query che combinano **SQL** (per interrogare le serie temporali) e **Cypher** (per il grafo).

La fase di studio iniziale ha analizzato lo stato dell'arte dell'interazione tra LLM e dati strutturati. Questo progetto si concentra sull'approccio "Direct Reasoner": si valuta la capacità del LLM di agire come interfaccia "Natural Language-to-Query" fornendogli un contesto strutturato (la struttura del grafo) e una richiesta utente. L'analisi è stata condotta testando quattro modelli di punta su un set di query di benchmark appositamente definite per un sottografo agricolo.

2. Tecnologie

Per raggiungere il nostro obiettivo, sono state usate diverse tecnologie.

- **PostgreSQL con estensioni:** Lo stack tecnologico è basato su PostgreSQL con due estensioni principali: **Apache AGE** (A Graph Extension) per la modellazione e l'interrogazione orientata ai grafi, e **TimescaleDB** per la gestione di serie temporali.
- **Linguaggi di query:**
 - **Cypher:** Linguaggio di query per database a grafo, oggetto centrale della generazione da parte dei LLM.
 - **SQL (Structured Query Language):** Linguaggio standard per database relazionali, considerato nel contesto ibrido abilitato da AGE.
- **Large Language Models (LLM):** Sono stati valutati quattro modelli principali tramite le rispettive interfacce web: ChatGPT, Gemini, Claude e DeepSeek.
- **Strumenti di sviluppo e analisi:**
 - **Linguaggio di programmazione:** Python è stato il linguaggio principale utilizzato per lo sviluppo degli script di analisi e valutazione.
 - **Formati dati:** JSON (per la definizione delle strutture di grafo) e YAML (per la definizione dei prompt e delle query di benchmark).
 - **Piattaforme:** GitHub per il versionamento del codice e Google Workspace (Docs) per la documentazione della ricerca.

3. Studio e Approfondimenti Teorici

Una parte significativa del tirocinio è stata dedicata all'analisi dello stato dell'arte per costruire una solida base teorica prima della sperimentazione.

- **Database NoSQL e grafi:** È stata condotta un'analisi delle diverse categorie di database NoSQL (Document, Key-Value, Column-family, Graph), con un focus sui vantaggi e sui casi d'uso dei database a grafo. Sono state approfondite le caratteristiche di Neo4j e PostgreSQL/AGE e le peculiarità del linguaggio Cypher.
- **LLM per dati strutturati:** È stata studiata la letteratura scientifica per comprendere le sfide (es. ambiguità terminologica, allineamento tra linguaggio naturale e strutture dati) e gli approcci esistenti (es. Direct Reasoning, fine-tuning specializzato) nell'utilizzare i LLM per generare query valide per interrogazioni su DBMS.
- **Prompt engineering:** È stato approfondito lo studio delle tecniche per costruire prompt efficaci, come zero-shot e few-shot. Si è compreso che fornire una descrizione dettagliata della struttura del database e un template di risposta è una tecnica cruciale per contestualizzare la richiesta e standardizzare l'output.

4. Metodologia

La parte pratica si è concentrata sulla progettazione e l'esecuzione di un benchmark per valutare quantitativamente i modelli LLM.

4.1 Progettazione del benchmark

1. Definizione progressiva della struttura del grafo: Per valutare come il livello di dettaglio nel prompt influenzi la capacità dei LLM, sono state definite tre versioni progressive della struttura:

- **Versione 1:** Solo la struttura base del grafo (nodi e relazioni) senza dati esemplificativi
- **Versione 2:** Struttura arricchita con tutte le proprietà, presenti nei nodi
- **Versione 3:** Struttura completa che includeva anche la descrizione della tabella relazionale "measurements", una Hypertable di Timescale, con al suo interno le varie misurazioni dei Divice e la componente SQL delle query ibride serve per interrogare questa tabella

Questo approccio graduale ha permesso di isolare l'impatto dell'arricchimento semantico sulla qualità delle query generate.

2. Definizione delle query di benchmark: È stato creato un set di 10 query in linguaggio naturale di complessità crescente. Le query spaziavano da semplici interrogazioni strutturali a richieste semantiche e inferenziali più complesse, fino a query che coinvolgevano sia il grafo che la tabella "measurements".

3. Creazione del ground truth: Per ogni richiesta, è stata scritta manualmente la query Cypher corretta, che funge da riferimento per la valutazione.

4. Progettazione del prompt: È stata definita una struttura di prompt modulare, che forniva al LLM la descrizione della struttura del grafo, istruzioni chiare su come formulare la risposta e la specifica richiesta in linguaggio naturale. L'obiettivo era guidare il modello a generare la query basandosi esclusivamente sul contesto fornito.

4.2 Raccolta e valutazione delle risposte

La generazione delle query è stata condotta in modo manuale per simulare fedelmente l'interazione di un utente finale con le interfacce web dei modelli. Per ciascuno dei quattro LLM, è stato fornito un prompt contenente la descrizione della

struttura del dato e le istruzioni per la risposta. Le query Cypher generate da ciascun modello sono state quindi raccolte e salvate per l'analisi successiva.

La valutazione è stata automatizzata tramite uno script Python appositamente sviluppato. I criteri di valutazione si basavano sul confronto tra il risultato della query generata dal LLM e il ground truth, considerando il numero di nodi e archi restituiti. La metrica era simmetrica: sia i dati mancanti che quelli in eccesso rispetto al ground truth contribuivano negativamente al punteggio.

I risultati sono stati classificati in tre categorie:

- **Corretto:** La query è sintatticamente corretta e il risultato coincide esattamente con il ground truth.
- **Mismatch (incompleto/inesatto):** La query è sintatticamente corretta ma il risultato è incompleto (mancano dati) o impreciso (contiene dati extra).
- **Errore (sintassi):** La query non è valida e fallisce l'esecuzione.

5. Risultati

5.1 Analisi preliminare: impatto dell'arricchimento del Contesto

Per determinare la configurazione ottimale per il benchmark finale, è stata condotta un'analisi preliminare sulle tre versioni progressive della struttura del grafo. La Tabella 1 mostra l'evoluzione delle performance per Gemini attraverso le diverse versioni:

Versione	Query Corrette	Mismatch	Errori	Note Principali
V1: Struttura base	1	7	2	Elevate hallucination e dati extra
V2: Con property	2	6	2	Miglioramento stabilità sintattica
V3: Completa (+measurements)	2	7	1	Miglioramento stabilità sintattica

Tabella 1: Evoluzione delle performance di Gemini

L'analisi comparativa rivela che l'arricchimento del contesto migliora principalmente la stabilità sintattica, ma non elimina completamente i problemi di accuratezza semantica:

- Nella **Versione 1**, la mancanza di dati esemplificativi ha portato a un elevato numero di hallucination, con il modello che tendeva a "inventare" proprietà o assumere strutture dati non presenti
- La **Versione 2** ha significativamente ridotto gli errori di interpretazione, fornendo al modello riferimenti concreti su cui basare la generazione delle query
- La **Versione 3** ha dimostrato il miglioramento nella gestione della tabella "measurements", sebbene con risultati variabili tra i diversi modelli testati

Questo pattern è stato osservato in tutti i modelli testati, sebbene con valori diversi, confermando che la completezza del contesto è un fattore critico per la generazione affidabile di query.

5.2 Benchmark finale

Sulla base dei risultati dell'analisi preliminare, il benchmark finale è stato condotto utilizzando la **Versione 3**, con la nostra metrica di valutazione.

Modello LLM	Corretto	Mismatch	Errore
ChatGPT	0	4	6
Claude	2	2	6
Gemini	2	7	1
DeepSeek	3	4	3

Tabella 2: Performance dei modelli LLM sul benchmark finale

I risultati rivelano che DeepSeek ottiene il numero più alto di query "Corrette" (3 su 10), sebbene con errori distribuiti. Gemini mantiene la migliore robustezza sintattica (solo 1 errore) ma presenta il maggior numero di mismatch (7). ChatGPT mostra le maggiori difficoltà, senza query completamente corrette e con 6 errori di sintassi.

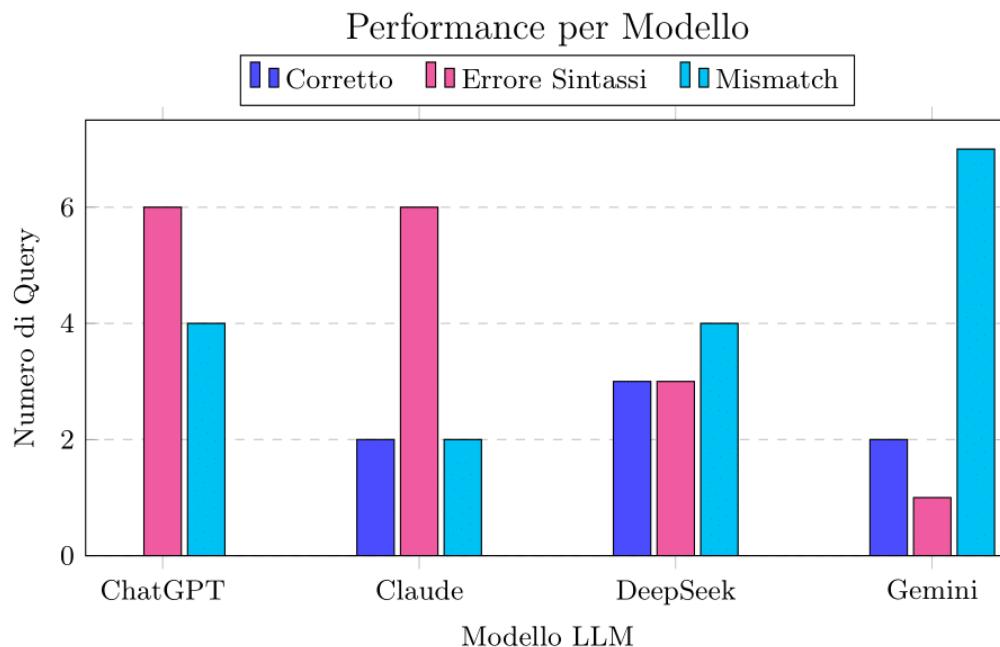


Figura 1: Confronto delle performance dei quattro LLM

Sull'intero set di 40 tentativi (4 modelli \times 10 query):

- Solo il **17.5%** (7/40) delle query risulta completamente corretta
- Il **42.5%** (17/40) produce risultati parziali o imprecisi (mismatch)
- Il **40.0%** (16/40) fallisce per errori di sintassi

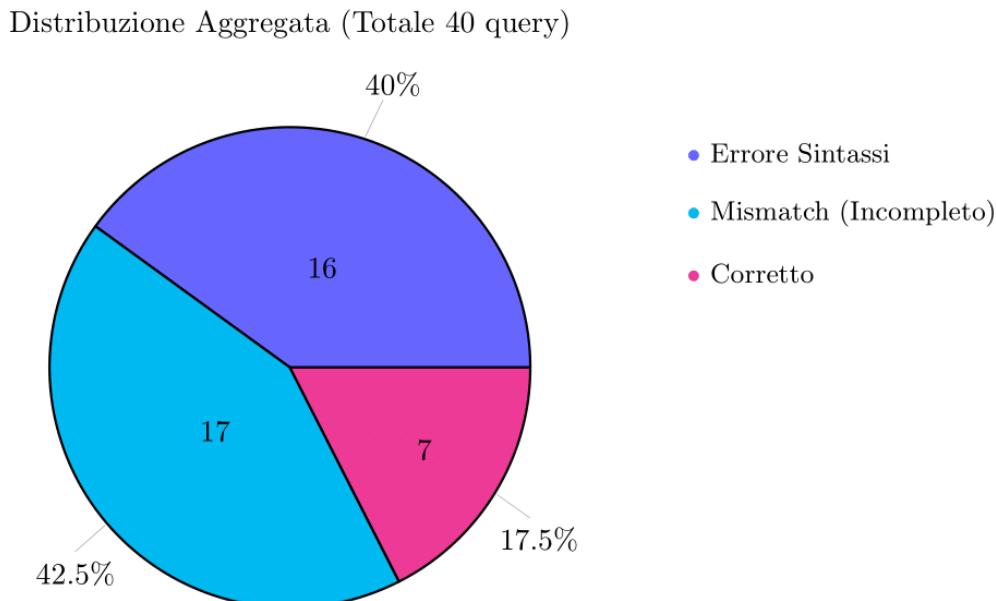


Figura 2: Distribuzione aggregata con metrica simmetrica

5.3 Analisi dettagliata dei risultati

DeepSeek - Il maggior numero di query corrette ma con errori distribuiti

- **Punti di forza:** 3 query perfettamente corrette, il miglior risultato assoluto
- **Punti critici:** 4 query con mismatch e 3 errori di sintassi
- **Problemi ricorrenti:** Errori di casting ("cannot cast type json to agtype") e problemi con alias nelle sottoquery

Gemini - Robusto sintatticamente ma con precisione variabile

- **Punti di forza:** Solo 1 errore di sintassi, dimostra la migliore comprensione della sintassi Cypher
- **Punti critici:** 7 query con mismatch, principalmente per dati extra o mancanti
- **Problemi ricorrenti:** Gestione eccessivamente inclusiva delle relazioni "hasDevice"

Claude - Buona precisione quando funziona, ma fragile sintatticamente

- **Punti di forza:** 2 query perfettamente corrette
- **Problema principale:** 6 errori di sintassi per uso di funzioni non standard ("function ANY/distance does not exist")

ChatGPT - Le maggiori difficoltà complessive

- **Criticità:** Nessuna query completamente corretta, 6 errori di sintassi

- **Pattern errori:** Accesso improprio a proprietà JSON ("invalid input syntax") e gestione alias ("could not find rte")

5.4 Analisi degli errori nel benchmark finale

L'analisi degli errori di sintassi nel benchmark finale rivela che i modelli commettono errori specifici e ricorrenti:

- Claude ha spesso tentato di usare funzioni non standard o non supportate.
- ChatGPT ha mostrato difficoltà nell'accesso a proprietà nidificate e nella gestione degli alias nelle query.
- Un errore comune a tutti i modelli (tranne Claude in un caso) è stata la gestione incorretta degli alias nelle sotto-query o nelle operazioni di aggregazione.

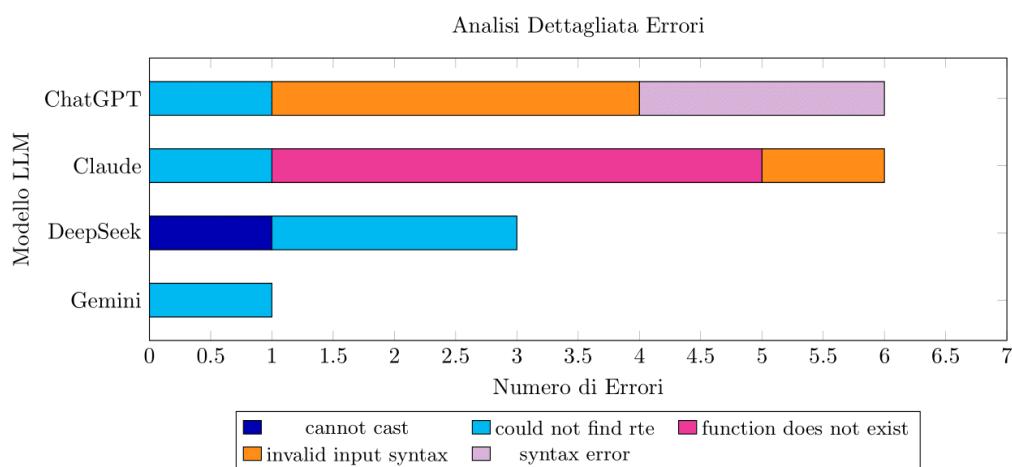


Figura 3: Analisi dei tipi di errori di sintassi per modello nel benchmark finale

L'analisi complessiva conferma che l'arricchimento progressivo del contesto ha un impatto positivo misurabile su tutti i modelli. Tuttavia, non elimina completamente le criticità: anche nella versione più completa (V3), persistono errori di sintassi e mismatch, indicando che la qualità del contesto è necessario ma non sufficiente per una generazione perfetta di query.

6. Conclusioni

L'attività di tirocinio ha rappresentato un'opportunità fondamentale per acquisire competenze nell'utilizzo contemporaneo di database a grafo e intelligenza artificiale generativa.

L'attività sperimentale ha dimostrato che, sebbene i LLM mostrino capacità impressionanti, la loro affidabilità nella generazione end-to-end di query Cypher in contesti ibridi è ancora limitata. L'analisi condotta ha rivelato diversi punti chiave:

1. **Robustezza sintattica differenziata:** I modelli mostrano una variabilità significativa nella capacità di generare query sintatticamente corrette. Gemini si è distinto per la minore propensione agli errori di sintassi.
2. **Il problema dell'incompletezza:** Un numero elevato di query, sebbene sintatticamente valide, ha restituito risultati incompleti o imprecisi. Questo rappresenta un vero problema, in quanto l'utente finale potrebbe ricevere dati errati senza un evidente messaggio di errore.
3. **Pattern di errore ricorrenti:** L'analisi ha identificato pattern di errore specifici per modello (es. uso di funzioni non standard, gestione degli alias), utili per indirizzare future ricerche sul miglioramento di questi strumenti.
4. **Impatto progressivo del contesto:** L'arricchimento graduale della struttura del grafo (dalla versione base a quella completa con la tabella measurements) ha mostrato un **miglioramento incrementale delle performance** su tutti i modelli. In particolare, si è osservata una riduzione significativa delle hallucination e degli errori di interpretazione, dimostrando che la completezza del contesto fornito è un fattore determinante per l'accuratezza delle query generate.

Prima di iniziare non avevo mai svolto attività di ricerca e sviluppo; questa è stata la mia prima esperienza in tale ambito, il che ha reso il percorso particolarmente stimolante.

Pur avendo conoscenze di base sui linguaggi di interrogazione come SQL e Python, non avevo alcuna familiarità con i database NoSQL, in particolare con i database a grafo e linguaggi come Cypher. Questo ha comportato un processo di apprendimento intenso e progressivo, che ha richiesto studio, ricerca e applicazione pratica.

Questa esperienza mi ha permesso di sviluppare:

- Capacità di ricerca autonoma e di approfondimento di tecnologie innovative.

- Competenze tecniche nuove, soprattutto nell'interazione tra AI e database strutturati.
- Analisi critica dei risultati, integrando aspetti quantitativi e qualitativi.
- Consapevolezza dell'importanza del prompt engineering e della modellazione dei dati per migliorare le performance dei LLM.

7. Bibliografia

Durante la fase di studio sono state consultate le seguenti risorse:

- LLM-powered GraphQL Generator for Data Retrieval
- DBSM non relazionali NoSQL
- Graph DataBase Neo4j
- MongoDB a document-oriented DataBase
- Augmented Knowledge Graph Querying leveraging LLMs SparqlLM
- A survey of large language models for data challenges in graphs
- A Survey of Graph Retrieval-Augmented Generation for Customized Large Language Models
- CypherBench: Towards Precise Retrieval over Full-scale Modern Knowledge Graphs in the LLM Era
- Hybrid-LLM-GNN: integrating large language models and graph neural networks for enhanced materials property prediction
- Injecting Structured Knowledge into LLMs via Graph Neural Networks
- Next-Generation Database Interfaces: A Survey of LLM-Based Text-to-SQL